Final Project - Sentiment Analysis

Project due: 2024. 12. 18. 11:59 PM
Last updated: 2024. 12. 12. 11:00 AM

Project Goal

- 순차 코드로 구현되어 있는 딥 러닝 추론 프로그램을 병렬화/최적화
  - 총 4개의 계산 노드를 사용 (NVIDIA RTX TITAN 총 16장)
  - Pthread, OpenMP, MPI, CUDA 사용 가능
  - 외부 라이브러리 사용 불가능

Target Model

- Sentiment Analysis Model
  - Determining whether a given text sentence a positive or negative sentiment
  - CNN based model

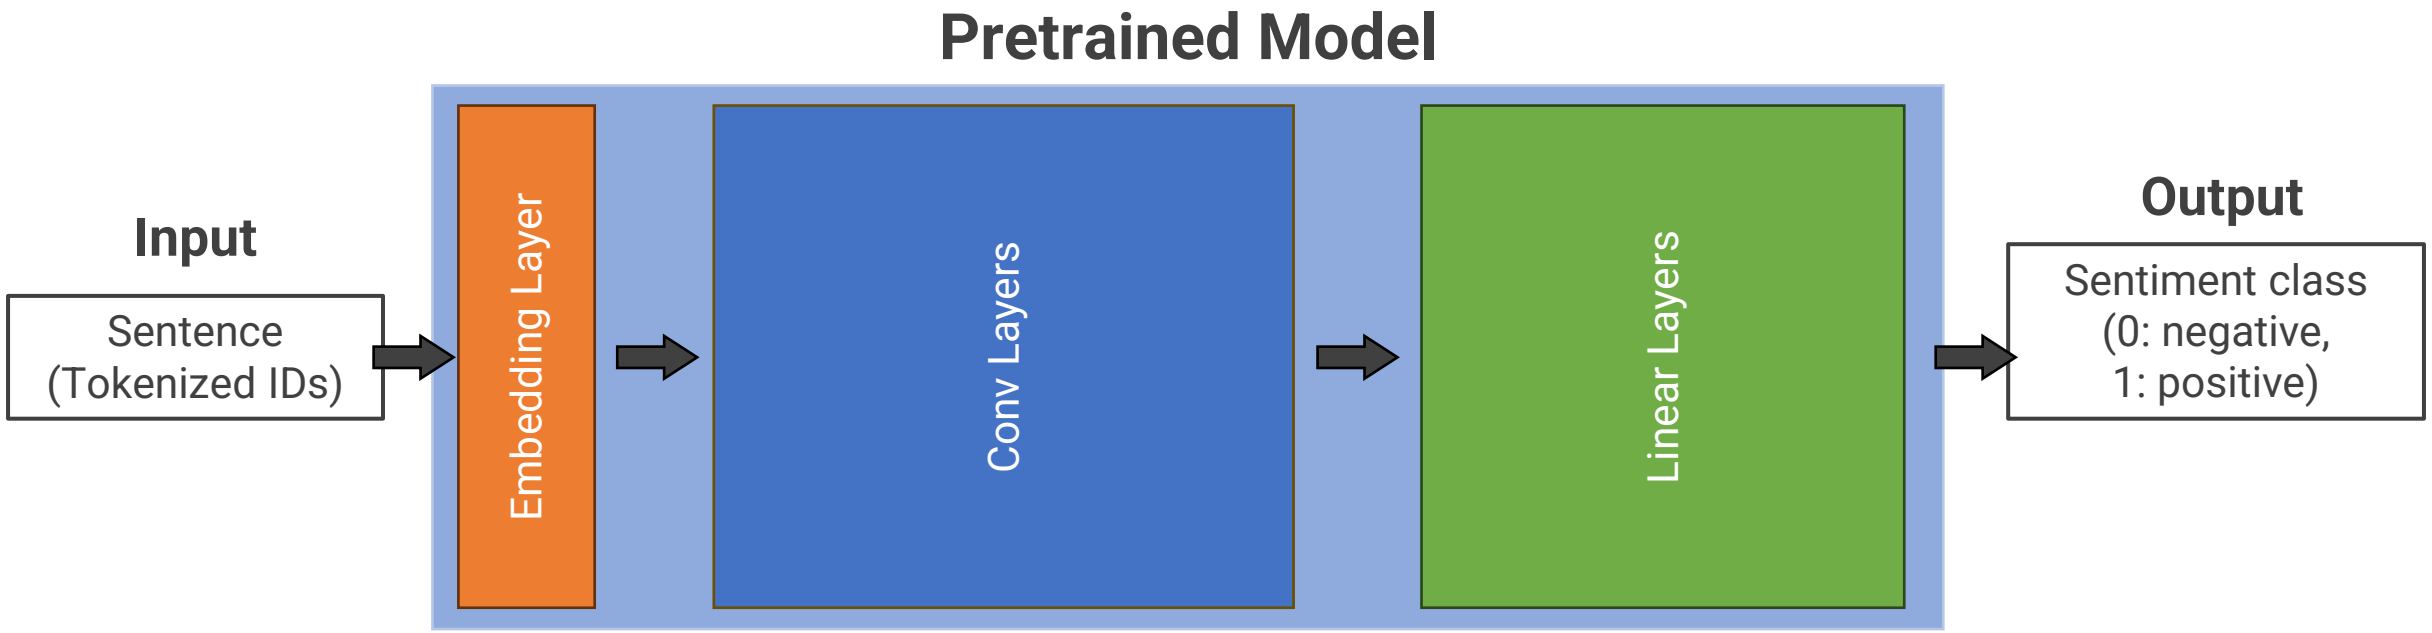

Background

Background - Tensor

- 딥 러닝에서 데이터를 다루는 단위
  - 뼈대 코드에 구현되어 있는 연산들은 tensor를 입출력으로 가짐
  - 정의: `include/tensor.h`, 구현: `src/tensor.cu`

1D Tensor
(e.g., Vector)

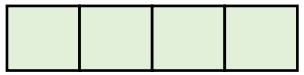

Shape = {4}

3D Tensor
(e.g., RGB image)

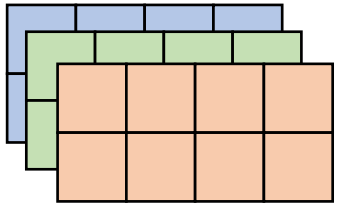

Shape = {3, 2, 4}

2D Tensor
(e.g., Matrix)

Shape = {2, 4}

4D Tensor
(e.g., CNN filter)

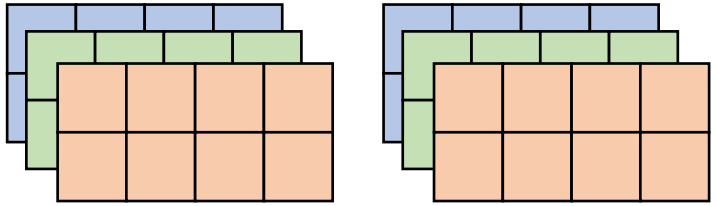

Shape = {2, 3, 2, 4}

Background - Model

- CNN based Sentiment Analysis Model
  - 정의: include/model.h, 구현: src/model.cu

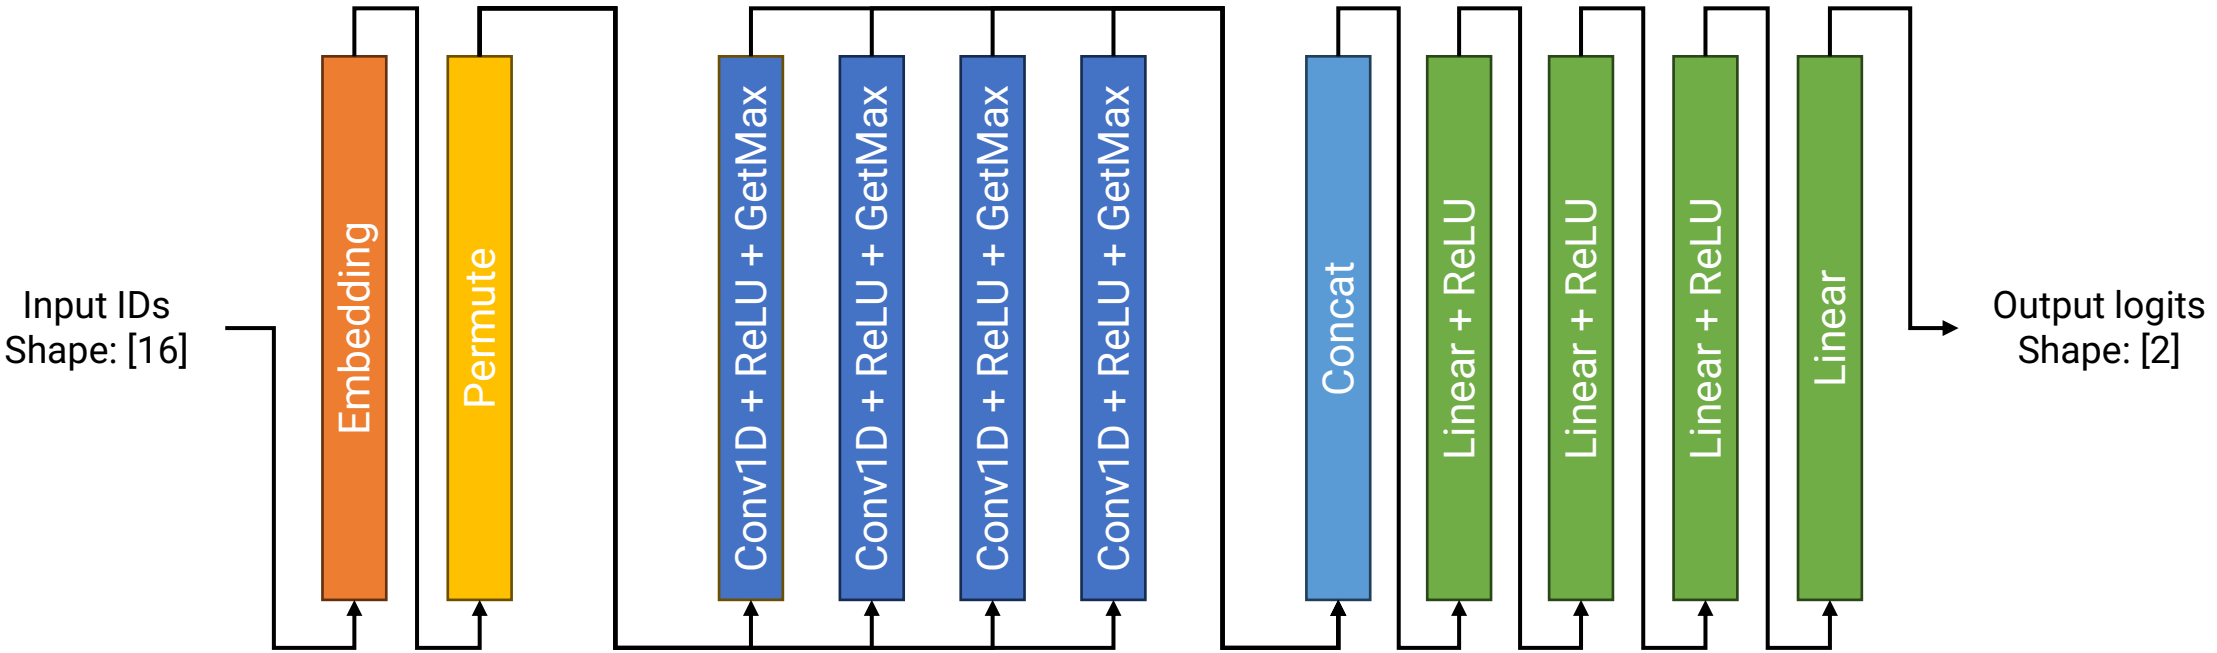

Background - Layers

- A set of nodes or neurons that processes and transforms input data
  - 정의: include/layer.h, 구현: src/layer.cu
  - 종류
    1. Embedding
    2. Permute
    3. Conv1D
    4. ReLU
    5. GetMax
    6. Concat
    7. Linear

Background – Embedding Layer

- Lookup table에서 토큰 값을 Index로 해서 Embedding vector를 반환
- 입출력
  - [in1] in: [s]
  - [in2]   w: [NUM_VOCAB, H]
  - [out] out: [s, H]

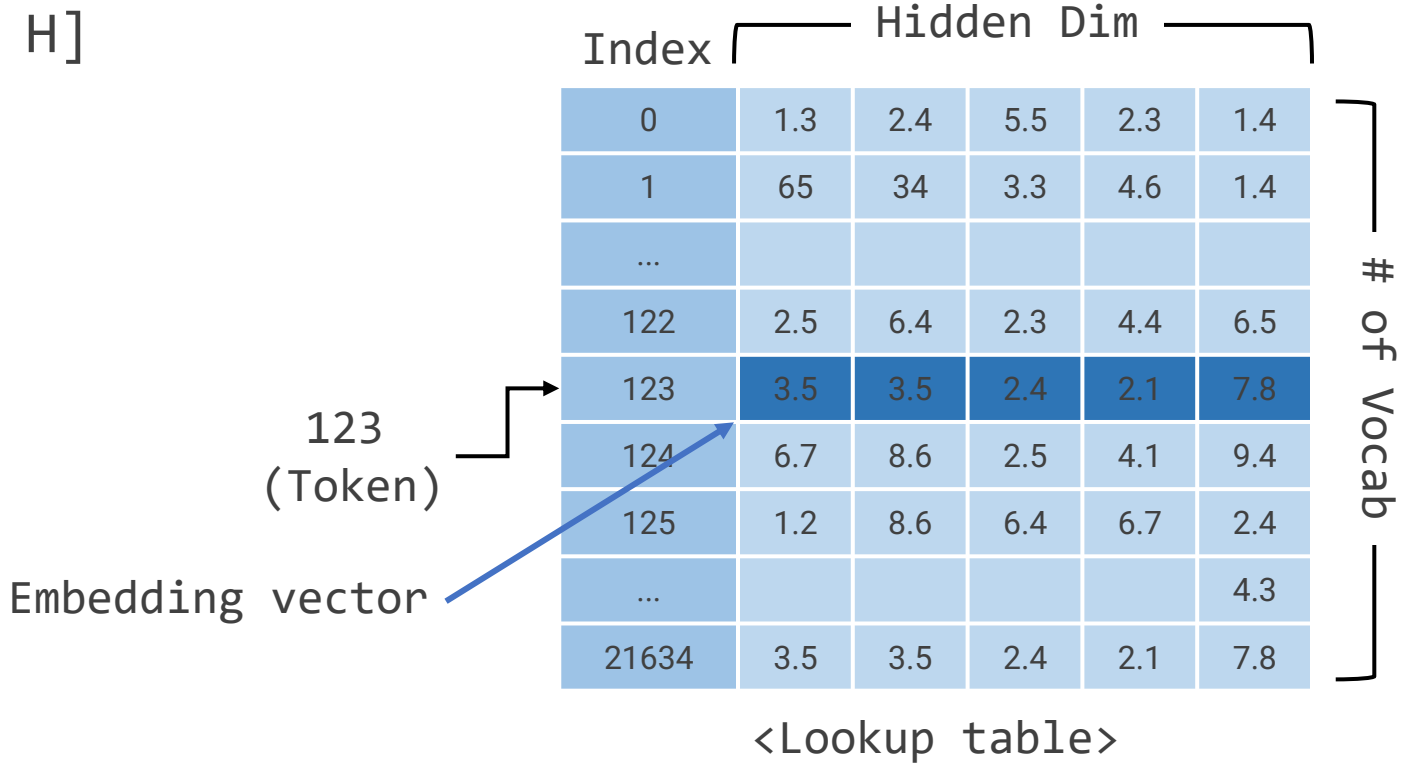

Background – Permute Layer

- 시퀀스(sequence) 차원과 임베딩(embedding) 차원의 순서를 변환
- 입출력
  - `[in]  in: [M, N]`
  - `[out] out: [N, M]`

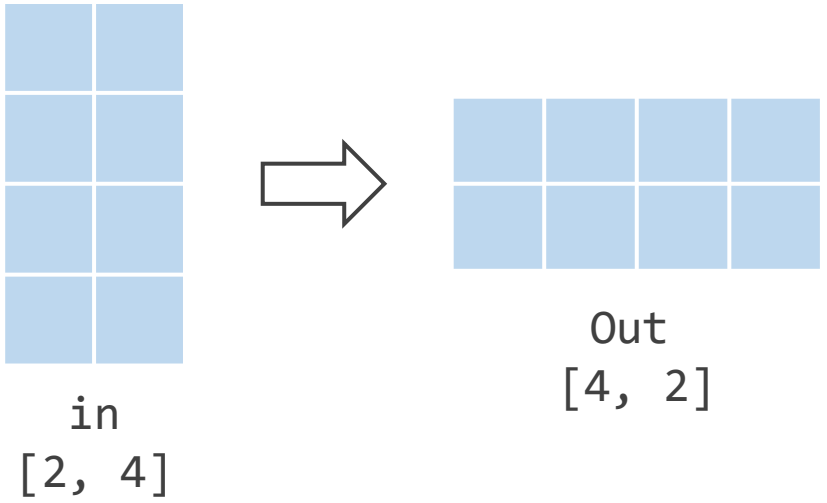

Background - Conv1D Layer

- 1차원 입력 데이터를 따라 1차원 filter를 이동하면서 합성곱
- 입출력
  - [in1] in: [C, s]
  - [in2]   w: [OC, C, K]
  - [in3]   b: [OC]
  - [out] out: [OC, os]

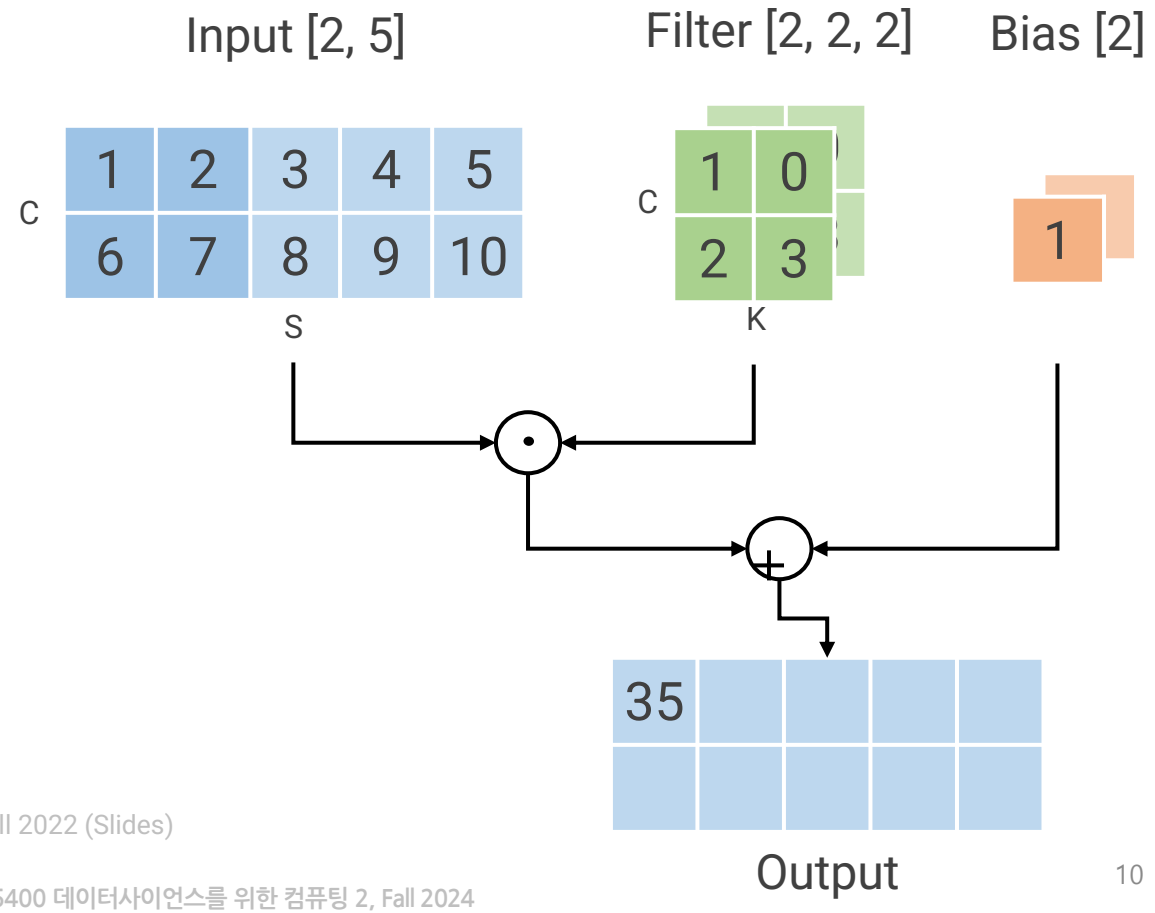

Background – GetMax Layer

- 시퀀스(sequence) 차원을 기준으로 최대값을 구하는 연산
  - $out = max(in,\ dim = -1)$
- 입출력
  - `[in]  in: [C, s]`
  - `[out] out: [C]`

Background – ReLU Layer

- ReLU(Rectified Linear Unit) 활성화 함수를 적용하는 연산
  - $out = max(0,\ in)$
- 입출력
  - `[in & out] inout: [N]`

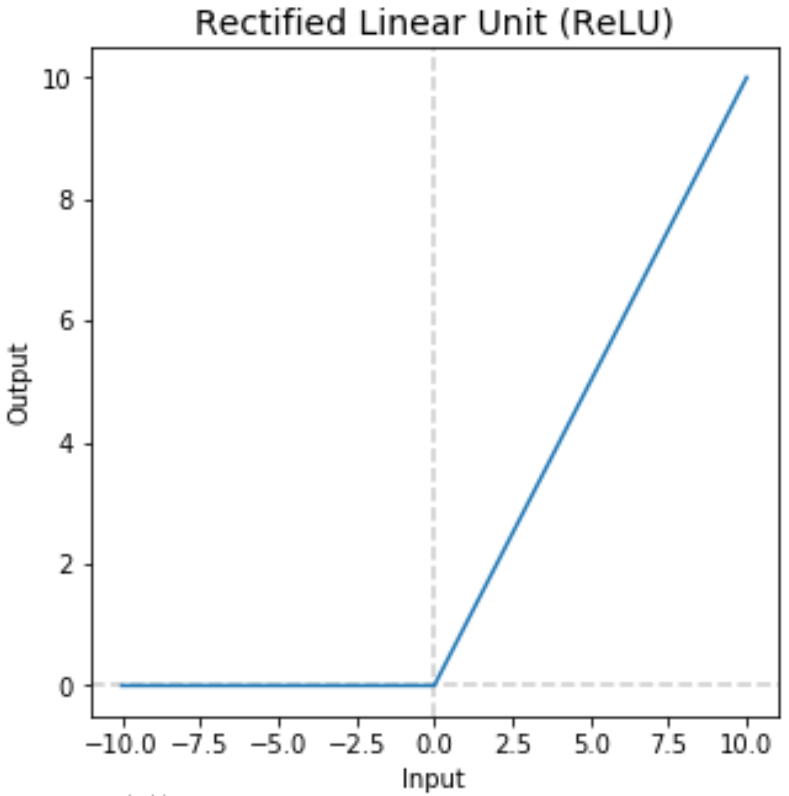

(출처 : https://towardsdatascience.com/deep-study-of-a-not-very-deep-neural-network-part-2-activation-functions-fd9bd8d406fc)

Background – Linear Layer

- 입력에 대한 선형 변환(Linear transformation)을 적용하는 연산
  - $out = in \times w^T + b$
- 입출력
  - `[in1]  in: [N]`
  - `[in2]   w: [M, N]`
  - `[in3]   b: [M]`
  - `[out] out: [M]`

Background - Layers (cont'd)

- 각 연산들에 대한 자세한 설명은 파이토치(PyTorch) 공식 문서 참고
  1. Embedding: https://pytorch.org/docs/stable/generated/torch.nn.Embedding.html
  2. Permute: https://pytorch.org/docs/stable/generated/torch.permute.html
  3. Conv1D: https://pytorch.org/docs/stable/generated/torch.nn.Conv1d.html
  4. ReLU: https://pytorch.org/docs/stable/generated/torch.nn.ReLU.html
  5. GetMax: https://pytorch.org/docs/main/generated/torch.max.html
  6. Concat: https://pytorch.org/docs/stable/generated/torch.concat.html
  7. Linear: https://pytorch.org/docs/stable/generated/torch.nn.Linear.html

Background - Layers (cont'd)

- 각 연산들의 이론적 배경을 이해할 필요는 없음
  - 딥 러닝에 대해 전혀 몰라도 프로젝트를 진행하는 데에 문제 없음
  - 연산들의 특징 및 연산 간 dependence 등을 이해하는 것이 중요
  - 뼈대 코드를 보고 각 연산이 어떤 일을 하는지 이해할 것

Skeleton Code & How to Run

Skeleton Code

- `/shpc/skeleton/final-project/` 를 복사하여 진행
- final-project

```
|- Makefile
|- run.sh
|- data
|      `- inputs.bin, answers.bin
|- include
|      `- tensor.h, layer.h, model.h
`- src
       `- tensor.cu, layer.cu, model.cu, main.cu
```

How to Run (1)

- make 커맨드로 컴파일
  - $ make

```
shpcta@elogin3:~/final-project$ make
mkdir -p obj
mpic++ -std=c++14 -O3 -Wall -march=native -mavx2 -mfma -mno-avx512f -fopenmp -I/usr/local/cuda/
include -Iinclude -c -o obj/main.o src/main.cpp
/usr/local/cuda/bin/nvcc  -Xcompiler=-std=c++14  -Xcompiler=-O3  -Xcompiler=-Wall  -Xcompiler=-
march=native  -Xcompiler=-mavx2  -Xcompiler=-mfma  -Xcompiler=-mno-avx512f  -Xcompiler=-fopenmp
  -Xcompiler=-I/usr/local/cuda/include  -Xcompiler=-Iinclude -c -o obj/model.o src/model.cu
/usr/local/cuda/bin/nvcc  -Xcompiler=-std=c++14  -Xcompiler=-O3  -Xcompiler=-Wall  -Xcompiler=-
march=native  -Xcompiler=-mavx2  -Xcompiler=-mfma  -Xcompiler=-mno-avx512f  -Xcompiler=-fopenmp
  -Xcompiler=-I/usr/local/cuda/include  -Xcompiler=-Iinclude -c -o obj/tensor.o src/tensor.cu
/usr/local/cuda/bin/nvcc  -Xcompiler=-std=c++14  -Xcompiler=-O3  -Xcompiler=-Wall  -Xcompiler=-
march=native  -Xcompiler=-mavx2  -Xcompiler=-mfma  -Xcompiler=-mno-avx512f  -Xcompiler=-fopenmp
  -Xcompiler=-I/usr/local/cuda/include  -Xcompiler=-Iinclude -c -o obj/layer.o src/layer.cu
cc -std=c++14 -O3 -Wall -march=native -mavx2 -mfma -mno-avx512f -fopenmp -I/usr/local/cuda/incl
ude -Iinclude -o main obj/main.o obj/model.o obj/tensor.o obj/layer.o -pthread -L/usr/local/cud
a/lib64 -lstdc++ -lcudart -lm -lmpi -lmpi_cxx
```

How to Run (2)

- `run.sh` 스크립트로 실행
  - 실행 스크립트를 이해하고 옵션들을 확인할 것
  - `$ ./run.sh -h`

```
shpcta@elogin3:~/final-project$ ./run.sh -h
salloc: Pending job allocation 867844
salloc: job 867844 queued and waiting for resources
salloc: job 867844 has been allocated resources
salloc: Granted job allocation 867844
 Usage: ./main [-i 'pth'] [-p 'pth'] [-o 'pth'] [-a 'pth'] [-n 'num_sentences'] [-v] [-w] [-h]
 Options:
  -i: Input binary path (default: ./data/inputs.bin)
  -p: Model parameter path (default: /home/s0/shpc_data/params.bin)
  -o: Output binary path (default: ./data/outputs.bin)
  -a: Answer binary path (default: ./data/answers.bin)
  -n: Number of input sentences (default: 1)
  -v: Enable validation (default: OFF)
  -w: Enable warm-up (default: OFF)
  -h: Print manual and options (default: OFF)
```

How to Run (3)

- 실행 예시
  - `$ ./run.sh -n 4 -w -v`

```
shpcta@elogin3:~/final-project$ ./run.sh -n 4 -w -v
salloc: Pending job allocation 867846
salloc: job 867846 queued and waiting for resources
salloc: job 867846 has been allocated resources
salloc: Granted job allocation 867846

================================================
 Model: Sentiment Analysis
------------------------------------------------
 Validation: ON
 Warm-up: ON
 Number of sentences: 4
 Input binary path: ./data/inputs.bin
 Model parameter path: /home/s0/shpc_data/params.bin
 Answer binary path: ./data/answers.bin
 Output binary path: ./data/outputs.bin
================================================

Initializing inputs and parameters...Done!
Warming up...Done!
Predicting sentiment...Done!
Elapsed time: 5.372378 (sec)
Throughput: 0.744549 (sentences/sec)
Finalizing...Done!
Saving outputs to ./data/outputs.bin...Done!
Validating...PASSED!
```

How to Run (4)

- 뼈대 코드에 제공된 파이썬 프로그램을 통해 실행 결과 확인
  - `$ python3 tools/bin2text.py <input_path> <output_path>`

```
shpcta@elogin3:~/final-project$ python3 tools/bin2text.py
Usage: python tools/bin2text.py <input_path> <output_path>
 E.g, python tools/bin2text.py data/inputs.bin data/outputs.bin
 <input_path> is the path to the inputs.bin file
 <output_path> is the path to the outputs.bin file
shpcta@elogin3:~/final-project$ python3 tools/bin2text.py data/inputs.bin data/outputs.bin
Sentence #1
 Input Sentence: i love sci-fi and am willing to put up with a lot . sci-fi <unk> are
 Tokenized IDs: [12, 119, 1036, 6, 218, 1744, 8, 277, 70, 20, 5, 178, 3, 1036, 0, 30]
 Predicted Sentiment: 1 (positive)
 Probability: 0.7057

Sentence #2
 Input Sentence: worth the entertainment value of a rental , especially if you like action movies . this
 Tokenized IDs: [308, 2, 721, 1099, 7, 5, 2148, 4, 261, 52, 26, 45, 228, 98, 3, 14]
 Predicted Sentiment: 1 (positive)
 Probability: 0.7004

Sentence #3
 Input Sentence: its a totally average film with a few <unk> action sequences that make the plot seem
 Tokenized IDs: [100, 5, 482, 809, 23, 20, 5, 174, 0, 228, 898, 15, 106, 2, 114, 321]
 Predicted Sentiment: 1 (positive)
 Probability: 0.5280

Sentence #4
 Input Sentence: star rating ***** saturday night **** friday night *** friday morning ** sunday night * monday
 Tokenized IDs: [341, 706, 5696, 1911, 306, 1829, 2204, 306, 2965, 2204, 1902, 3478, 2090, 306, 2551, 7681]
 Predicted Sentiment: 0 (negative)
 Probability: 0.7420
```

Project Rules & Restrictions

프로젝트 규칙 및 주의사항 (1)

- 수정 불가능한 파일
  - inputs.bin, answers.bin: 입력과 정답 바이너리 파일
  - params.bin: 학습된 모델 파라미터가 저장된 바이너리 파일
  - model.h, main.cpp, Makefile: 그 외 수정 불가한 파일

- 수정 가능한 파일 (제출 파일)
  - tensor.h, tensor.cu
  - layer.h, layer.cu
  - model.cu.
  - run.sh: 적절하게 **프로그램 실행 옵션을 추가 및 수정**하여 사용할 것
    - **프로젝트 제출 이후 성능 재현 및 평가는 ./run.sh -v 명령으로 실행할 것이므로 각자 최고 성능이 나오는 옵션(-n, -w 옵션 등)으로 ./run.sh 파일을 수정한 후 제출할 것**

프로젝트 규칙 및 주의사항 (2)

- 프로그램 로직 혹은 모델 구조를 변경하는 수정은 불허

- 가능한 수정의 예시
  - 메모리 레이아웃 변경, 루프 순서 변경, 패딩 데이터/연산 추가, 커널 병합(kernel fusion) 등

- 불가능한 수정의 예시
  - 시간 측정 부분(`predict_sentiment` 함수) 외에서 모델 추론 연산 수행
  - 동일한 출력을 만들어내는 다른 모델/알고리즘 사용 등

- **애매한 것은 조교에게 문의할 것**

프로젝트 규칙 및 주의사항 (3)

- CUDA 외의 라이브러리 사용 불가능
  - 사용 불가능한 라이브러리 예시: cuBLAS, cuDNN, clBLAS, MAGMA, BLIS, PyTorch, Tensorflow 등등
  - GPU 사용 시 CUDA를 권장하나, OpenCL을 꼭 사용하고 싶다면 조교에게 먼저 문의

- Tensor Core 사용 가능 (입력: FP16, 출력: FP16 or FP32)
  - 현재 뼈대 코드는 모두 FP32 (float) 데이터 타입으로 동작하며, Validation 또한 FP32로 진행하므로 데이터 타입과 타입 변환(casting)에 유의
  - 부동소수점(Floating point) 오차로 Validation에 실패하지 않도록 주의

- **애매한 것은 조교에게 문의할 것**

Grading & Submission

프로젝트 평가방법

- **성능 (80%)**
  - 성능 기준: Throughput (sentences/sec)
  - 하나의 입력 문장의 길이는 16개의 토큰으로 고정 (변경 불가)
  - 처리할 입력 문장의 개수는 본인이 원하는 값으로 설정 가능 (최대: 16384)
  - 1등부터 4등까지는 만점, 4등 대비 2배씩 성능이 감소할 때마다 10% 감점
  - Validation 실패 시 0점 처리

- **레포트 (20%)**
  - 파일명: report.pdf
  - 5 페이지 이내로 본인이 적용한 최적화 내용을 간략히 작성
  - 본인이 측정한 **1) 성능(Throughput)** 및 **2) 성능 화면 캡처 이미지** 첨부할 것

프로젝트 제출

- 마감 시간: 2024. 12. 18. 11:59 PM
  - 마감 시간을 초과하여 제출한 것에 대해서는 실격 처리
  - 실습 서버, 시스템 문제 등 천재지변에 준하는 경우 예외 처리

- `shpc-submit` 유틸리티를 사용하여 제출
- 제출 파일 (총 7개)
  - tensor.h, tensor.cu, layer.h, layer.cu, model.cu, run.sh
  - report.pdf
  - **프로젝트 제출 이후 성능 재현 및 평가는 오로지 ./run.sh -v 명령으로 실행되므로 입력 개수(-n)를 ./run.sh에 설정해둘 것**
    - **[X] ./run.sh -n 32 -w -v**
    - **[O] ./run.sh -v**

Comments

Comments (1)

- 각 연산의 특징, 연산 간 dependence 등을 파악하는 것이 중요
- 뼈대 코드를 먼저 잘 이해한 뒤에 시작하는 것을 추천

- 항상 근거를 가지고 최적화를 해야 함
  - 최적화에 앞서 어디가 문제인지 찾아내는 것이 기본
  - [X] '교수님이 말씀하시길, kernel fusion 이 좋다더라'
  - [O] 'Kernel launch 횟수가 너무 많으니, kernel fusion 을 통해 kernel launch overhead 를 줄이자'
  - [X] 'Convolution 연산이 제일 복잡해 보이니까 최적화 하는 게 좋지 않을까?'
  - [O] '실행 시간을 측정해보니 Convolution 연산이 가장 오래 걸리니까 이것부터 최적화 하자'

Comments (2)

- 해볼만한 것들
  - 여러 개의 입력을 묶음으로 처리 (batching)
  - Peak FLOPS 대비 얼마나 빠른지 계산
  - 커널 최적화
    - Matmul, Convolution 연산 최적화
    - Reduction
    - Kernel fusion
  - 프로파일링
    - 수업시간에 배운 Nsight Systems, Compute 사용

Updates

Updates

[24.12.12]

- ‘./Makefile’ 수정 (‘-arch=sm_70’ for TC)